Création d'un Tracker de prix en Python

Web scraping et analyse statistique de marché

Par : Mathis RINGENBACH, Matys PHILIPON-GOUIN, Emré YAPMIS

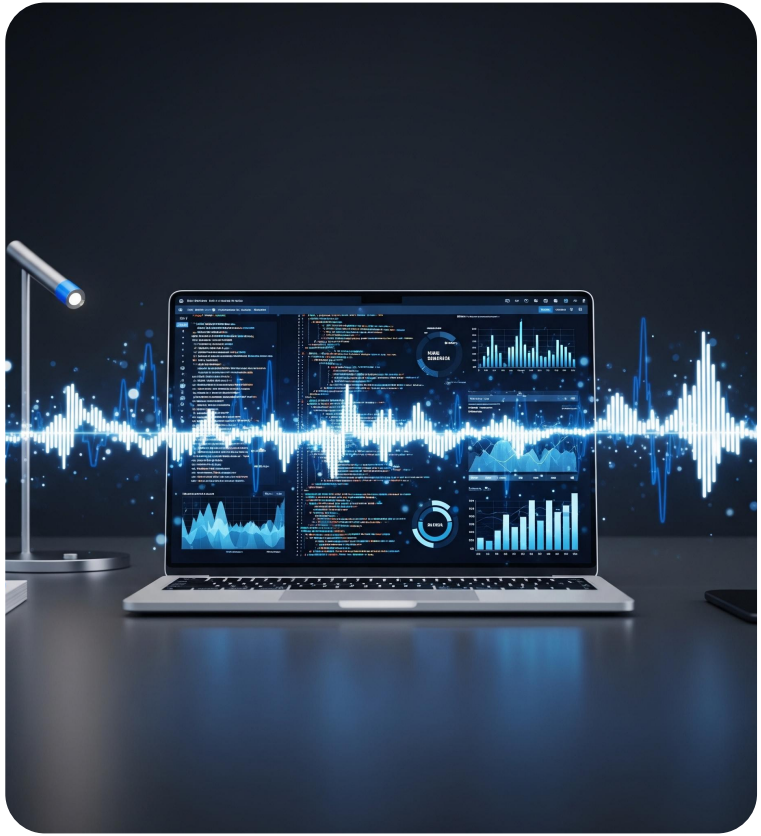

Le besoin et l'objectif

Automatisation

Automatiser la recherche d'un produit spécifique pour gagner en efficacité.

Extraction de données

Isoler les offres réelles et vérifiées directement depuis la plateforme Leboncoin.

Analyse du marché

Calculer la meilleure affaire en ignorant systématiquement le bruit et les publicités.

La Stack Technique

requests

Bibliothèque essentielle pour interroger le serveur et récupérer les données brutes.

BeautifulSoup

Utilisée pour analyser le HTML et extraire les informations pertinentes des pages Leboncoin.

statistics

Module natif pour calculer les moyennes et médianes afin d'évaluer le marché.

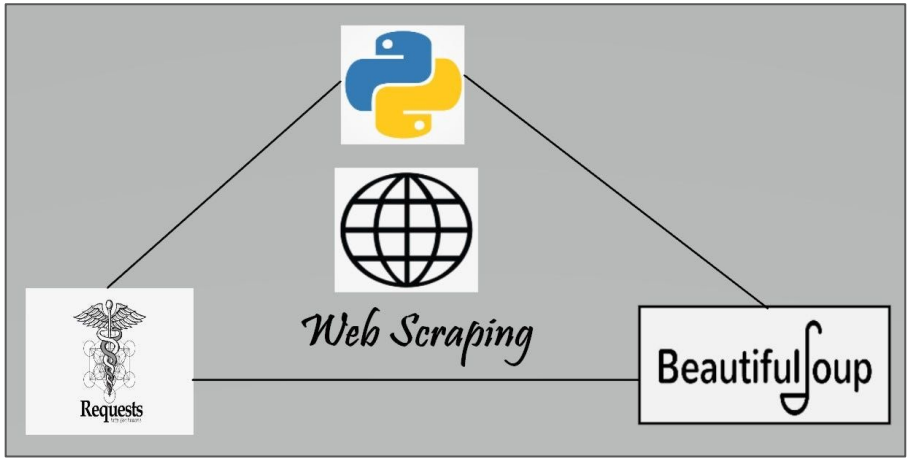

Défi technique n°1 : Contourner les blocages

Détection Anti-Robot

- Leboncoin bloque les requêtes automatisées basiques via leurs /robots.txt.
- Les scripts sont identifiés comme robots et rejetés.

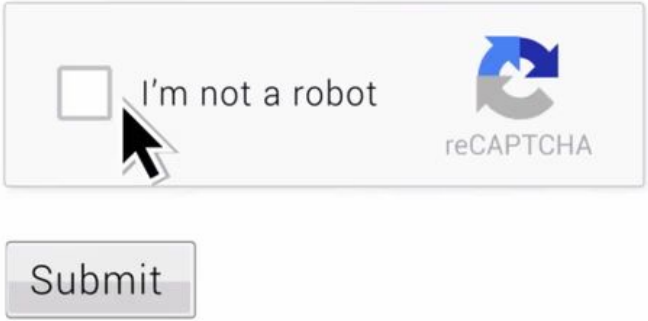

Solution : User-Agent

- Ajout d'un dictionnaire "User-Agent" personnalisé.
- Simule l'identité d'un vrai navigateur (Chrome, Firefox).
- Permet de passer sous les radars des pare-feux.

```
headers = {'User-Agent': 'Mozilla/5.0...'}
response = requests.get(url, headers=headers)
```

Extraction et ciblage CSS

Ciblage de la classe .s-item

Le script parcourt le code source HTML pour identifier chaque conteneur de produit marqué par la classe CSS ".s-item".

Collecte des attributs clés

Pour chaque objet trouvé, BeautifulSoup extrait précisément le titre, le prix formaté et l'URL directe de l'annonce.

```html
<!DOCTYPE html>
<html>
<head>
    <title>CSS</title>
    <style>
    .box{
        background-color: pink;
        width: 300px;
        height: 200px;
        margin: auto;
        font-size: 40px;
        text-align: center;
    }

    .box:hover{
        background-color: cyan;
    }

    h1, h2{
        color: black;
        text-align: center;
    }
    </style>
</head>

<body>
    <h1>Simplilearn</h1>
    <h2>:hover Pseudo-class</h2>
    <div class="box">
        My color changes if you hover over me!
    </div>
</body>
</html>
```

Défi technique n°2 : Le nettoyage de la donnée

Le chaos des prix bruts

- Les données extraites sont "sales" : symboles €, devises mixtes.
- Présence d'espaces insécables (\xa0) et de virgules trompeuses.

Solution : Normalisation Python

- Création d'une fonction de parsing dédiée.
- Suppression des caractères non numériques via regex.
- Conversion finale en type float pour les calculs statistiques.

```
def clean_price(raw):
return float(raw.replace('
€','').replace(',','.'))
```

Analyse et restitution

Moyenne et Médiane

Le programme calcule la moyenne globale et la médiane pour neutraliser l'impact des prix aberrants.

Offre la moins chère

Identification instantanée de l'annonce présentant le prix de vente le plus bas sur le marché actuel.

Calcul de l'économie

Calcul automatique du pourcentage d'économie réalisé par rapport à la moyenne du marché.

Bilan et évolutions futures

Un prototype rapide et fonctionnel prêt pour le déploiement.

Gestion de la pagination

Étendre l'extraction sur plusieurs pages pour analyser un volume de résultats plus important.

Interface Graphique (GUI)

Développer une interface conviviale pour faciliter l'utilisation sans connaissances en ligne de commande.

Export de données CSV/JSON
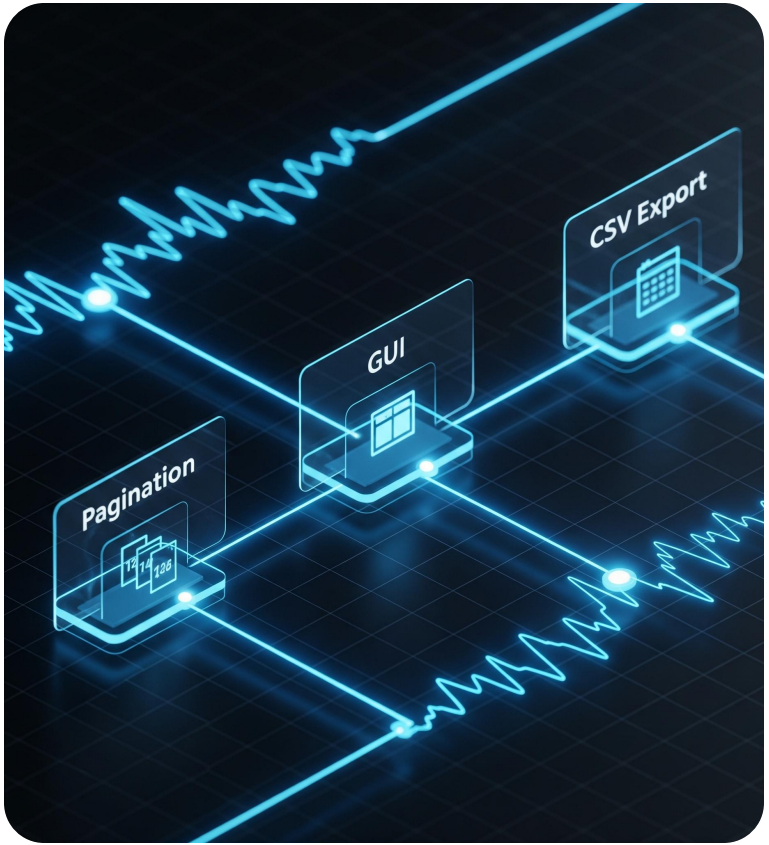
Permettre l'exportation structurée des résultats pour une analyse approfondie en format excel ou json.